

ProteusTyper: Desenvolvimento de um Pipeline para Identificação do Locus do Antígeno O em Genomas de *Proteus*

Carina Ferreira

1 Introdução

1.1 O gênero *Proteus*

O gênero *Proteus* pertence à família *Morganellaceae* e inclui bactérias Gram-negativas amplamente distribuídas no ambiente e no trato gastrointestinal de humanos e animais [1]. Entre as espécies deste gênero, *Proteus mirabilis* destaca-se pela sua importância clínica, sendo frequentemente associada a infecções do trato urinário, especialmente em doentes portadores de cateteres urinários.

Para além das infecções urinárias, *P. mirabilis* pode também estar envolvida em infecções de feridas, septicémias e outras infecções associadas aos cuidados de saúde. A capacidade desta bactéria para formar biofilmes e colonizar dispositivos médicos torna-a um importante agente patogénico oportunista.

Com o aumento da disponibilidade de genomas bacterianos completos, tornou-se possível utilizar abordagens bioinformáticas para caracterizar geneticamente diferentes estirpes e compreender melhor a diversidade existente dentro deste gênero.

1.2 Lipopolissacarídeo e antígeno O

A membrana externa das bactérias Gram-negativas contém uma molécula denominada lipopolissacarídeo (LPS), constituída por três regiões principais: o lípido A, o núcleo oligossacarídico e o antígeno O [4].

O antígeno O corresponde à porção mais externa do LPS e apresenta elevada variabilidade estrutural entre diferentes estirpes bacterianas. Esta variabilidade resulta das diferenças nos açúcares que compõem esta estrutura e nos genes responsáveis pela sua biossíntese.

Devido à sua diversidade, o antígeno O é frequentemente utilizado em estudos de serotipagem e epidemiologia molecular, permitindo distinguir diferentes grupos bacterianos [5].

1.3 O locus O

Os genes envolvidos na biossíntese do antígeno O encontram-se agrupados numa região específica do genoma designada por locus O.

Esta região contém genes responsáveis pela síntese, modificação e transporte dos açúcares que constituem o antígeno O. Enquanto algumas regiões do locus tendem a ser conservadas, outras apresentam elevada variabilidade genética, originando diferentes estruturas de antígeno O.

Em *Proteus spp.*, o locus O encontra-se geralmente delimitado pelos genes conservados *secB* e *cpxA*. Estes genes funcionam como genes fronteira da região de interesse, permitindo a sua localização e extração automática a partir de genomas completos.

1.4 O locus O




Figura 1: Representação simplificada da localização do locus O entre os genes secB e cpxA.

A variabilidade observada nesta região torna o locus O particularmente interessante para estudos de tipagem molecular e caracterização genômica [5].




Figura 2: Representação esquemática da organização do locus O. Os genes conservados delimitam uma região central variável responsável pelas diferenças observadas nos antígenos O.

1.5 Motivação

A identificação e caracterização de loci O é frequentemente realizada através da utilização de múltiplas ferramentas bioinformáticas e de diversas etapas manuais de análise.

Este processo pode tornar-se moroso, especialmente quando se pretende analisar um grande número de genomas. Além disso, a utilização de diferentes ferramentas de forma independente pode dificultar a reprodutibilidade dos resultados obtidos.

Neste contexto surgiu a necessidade de desenvolver uma metodologia capaz de automatizar a identificação, extração e comparação de loci O em genomas de *Proteus spp.*

1.6 Objetivos

O principal objetivo deste projeto consistiu no desenvolvimento de uma ferramenta bioinformática designada ProteusTyper para apoio à análise de loci O em genomas de *Proteus spp.*

Os objetivos específicos incluíram:

- Construção de uma base de referência contendo loci O descritos para diferentes espécies do género *Proteus*;
- Desenvolvimento de métodos para identificação automática do locus O;
- Implementação de procedimentos de anotação genética utilizando Prokka;
- Desenvolvimento de análises comparativas baseadas em matrizes de presença e ausência de genes;
- Integração das diferentes etapas numa pipeline automatizada;
- Criação de uma base para futuras abordagens de tipagem molecular.

2 Estado da Arte

2.1 Serotipagem baseada no antígeno O

A serotipagem constitui uma das abordagens mais utilizadas para a diferenciação de estirpes bacterianas. Nas bactérias Gram-negativas, esta classificação é frequentemente baseada nas diferenças observadas no antígeno O, a região mais externa do lipopolissacarídeo.

Tradicionalmente, a determinação dos serotipos é realizada através de métodos laboratoriais que recorrem a anticorpos específicos para reconhecer diferentes antígenos. Embora estes métodos apresentem utilidade clínica e epidemiológica, a sua aplicação pode ser limitada pela disponibilidade de reagentes, custos laboratoriais e tempo necessário para obtenção dos resultados.

2.2 Abordagens genómicas

O desenvolvimento das tecnologias de sequenciação permitiu a utilização de abordagens genómicas para a caracterização de bactérias [2]. A disponibilidade crescente de genomas completos possibilitou a análise direta das regiões responsáveis pela biossíntese do antígeno O, permitindo substituir ou complementar os métodos laboratoriais tradicionais.

A análise de sequências genómicas apresenta diversas vantagens, incluindo a possibilidade de estudar simultaneamente múltiplos isolados, a facilidade de armazenamento dos dados e a reprodutibilidade das análises realizadas.

2.3 Utilização do BLAST na identificação de loci

Uma das abordagens mais utilizadas para a análise de loci bacterianos consiste na utilização da ferramenta BLAST (*Basic Local Alignment Search Tool*). Esta ferramenta permite comparar sequências de ADN ou proteínas com bases de dados de referência, identificando regiões semelhantes.

Apesar da sua utilidade, a análise baseada exclusivamente em pesquisas BLAST pode tornar-se morosa quando aplicada a um elevado número de genomas. Além disso, a interpretação dos resultados continua frequentemente dependente da intervenção manual do utilizador.

2.4 Necessidade de automatização

A análise de loci O envolve habitualmente várias etapas consecutivas, incluindo a identificação da região de interesse, a anotação dos genes presentes, a comparação com sequências de referência e a interpretação dos resultados obtidos.

A realização manual destas etapas pode dificultar a reprodutibilidade das análises e aumentar significativamente o tempo necessário para processar novos genomas.

Neste contexto, torna-se relevante o desenvolvimento de ferramentas capazes de integrar estas tarefas numa única pipeline automatizada, reduzindo a intervenção manual e permitindo uma análise mais rápida e consistente [2].

2.5 Motivação para o desenvolvimento do ProteusTyper

O ProteusTyper foi desenvolvido com o objetivo de integrar diferentes etapas da análise de loci O numa única ferramenta.

A abordagem proposta permite automatizar a extração do locus O, a anotação genética, a comparação com uma base de referência e a geração de resultados de forma estruturada.

Desta forma, pretende-se disponibilizar uma metodologia reprodutível que possa servir de base para futuras abordagens de tipagem molecular em *Proteus spp.*

Tabela 1: Comparação entre diferentes abordagens de análise de loci O.

Método	Vantagens	Limitações
Serotipagem clássica	Utilizada há vários anos	Necessita de laboratório
BLAST manual	Fácil de implementar	Processo demorado
Análise manual de loci	Flexível	Pouco reprodutível
ProteusTyper	Automatização e integração	Ainda em desenvolvimento

3 Materiais e Métodos

3.1 Conjunto de dados

O desenvolvimento do projeto foi dividido em duas fases principais. Numa primeira fase foi realizado um estudo exploratório utilizando seis genomas de *Proteus mirabilis*. Esta fase teve como objetivo compreender a organização dos loci O e desenvolver as metodologias necessárias para as análises posteriores.

Numa segunda fase, a metodologia desenvolvida foi aplicada a um conjunto mais alargado de vinte e seis genomas de *Proteus mirabilis*, permitindo avaliar o funcionamento da pipeline implementada.

Todos os genomas utilizados encontravam-se em formato GenBank (.gbff), permitindo o acesso simultâneo às sequências genómicas e respetivas anotações.

3.2 Fase 1: análise exploratória dos loci O

A primeira fase do projeto teve como objetivo estudar a variabilidade genética dos loci O presentes em diferentes genomas de *P. mirabilis*.

Inicialmente foram identificados os genes conservados *secB* e *cpxA*, utilizados como genes fronteira da região de interesse. A localização destes genes permitiu determinar automaticamente os limites do locus O em cada genoma analisado.

Após a extração dos loci O, foi realizada uma análise comparativa da composição genética destas regiões.

3.3 Anotação genética com Prokka

Os loci extraídos foram anotados utilizando a ferramenta Prokka. Esta ferramenta permite identificar genes codificantes e atribuir funções putativas com base em bases de dados biológicas previamente anotadas.

A utilização do Prokka permitiu uniformizar a anotação dos genes presentes nos diferentes loci, facilitando as comparações realizadas posteriormente.

Os ficheiros produzidos durante esta etapa foram utilizados para construir as matrizes de presença e ausência dos genes identificados.

3.4 Construção da matriz de presença e ausência

Após a anotação genética foi construída uma matriz binária de presença e ausência.

Nesta matriz, cada linha corresponde a um gene identificado e cada coluna corresponde a um genoma analisado. O valor 1 indica a presença de um determinado gene, enquanto o valor 0 indica a sua ausência.

Esta representação permitiu comparar diretamente os perfis genéticos dos diferentes loci O.

3.5 Heatmap e clustering hierárquico

A matriz de presença e ausência foi utilizada para gerar um heatmap representativo da distribuição dos genes entre os diferentes genomas.

Posteriormente foi realizada uma análise de clustering hierárquico utilizando a biblioteca SciPy. Esta abordagem permitiu agrupar genomas com perfis genéticos semelhantes e identificar possíveis padrões de conservação e variabilidade genética.

Os resultados obtidos forneceram uma primeira visão global da diversidade genética existente nos loci O analisados.

3.6 Análise de genes core e accessory

Foi ainda realizada uma análise de genes core e accessory.

Os genes core correspondem aos genes presentes em todos os genomas analisados, estando normalmente associados a funções essenciais e mais conservadas.

Por outro lado, os genes accessory encontram-se presentes apenas num subconjunto dos genomas estudados, contribuindo para a variabilidade observada entre diferentes loci O.

Esta análise permitiu identificar regiões mais conservadas e regiões mais variáveis dentro do conjunto de dados analisado.

3.7 Construção da base de referência

Após a análise exploratória foi construída uma base de referência contendo loci O previamente descritos para diferentes espécies do género *Proteus*.

As sequências foram obtidas a partir de registos públicos disponíveis no GenBank. Para cada sequência foram armazenados metadados relevantes, incluindo o número de acesso, a descrição do locus e a espécie correspondente.

A base de referência construída constitui um dos componentes centrais do ProteusTyper, permitindo a comparação de novos genomas com perfis previamente descritos.

accession	description	organism	source	strain	isolate	serotype	notes
KY710685	Proteus vulgaris strain CCUG 14635 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	CCUG 14635		O1	
KY710686	Proteus vulgaris strain 2-Prk5/57 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	2-Prk5/57		O2	
KY710687	Proteus mirabilis strain PrK 12/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 12/57		O5	
KY710688	Proteus mirabilis strain PrK 14/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 14/57		O6	
KY710689	Proteus vulgaris strain PrK 17/57 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	PrK 17/57		O8	
KY710690	Proteus mirabilis strain PrK 18/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 18/57		O9	
KY710691	Proteus mirabilis strain PrK 24/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 24/57		O11	
KY710692	Proteus vulgaris strain PrK 25/57 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	PrK 25/57		O12	
KY710693	Proteus mirabilis strain PrK 26/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 26/57		O13	
KY710694	Proteus mirabilis strain PrK 28/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 28/57		O14ab	
KY710695	Proteus mirabilis strain PrK 31/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 31/57		O16	
KY710696	Proteus vulgaris strain CCUG 4652 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	CCUG 4652		O17	
KY710697	Proteus mirabilis strain PrK 34/57 O antigen gene cluster, complete sequence	Proteus mirabilis	Proteus mirabilis	PrK 34/57		O18	
KY710698	Proteus vulgaris strain PrK 37/57 O antigen gene cluster, complete sequence	Proteus vulgaris	Proteus vulgaris	PrK 37/57		O19a	

Figura 3: Excerto da base de referência construída a partir de sequências obtidas no GenBank.

3.8 Fase 2: desenvolvimento do ProteusTyper

Após a validação da metodologia através da análise exploratória dos seis genomas, procedeu-se ao desenvolvimento do ProteusTyper.

O principal objetivo desta ferramenta consistiu na automatização da identificação e análise de loci O em genomas de *Proteus spp.*, integrando várias etapas bioinformáticas num único workflow.

Nesta fase foi utilizado um conjunto de vinte e seis genomas de *Proteus mirabilis*, permitindo avaliar a capacidade da ferramenta para processar múltiplos genomas de forma consistente e reprodutível.

3.9 Identificação da espécie

A primeira etapa da pipeline consiste na identificação da espécie presente no genoma analisado.

Esta etapa permite verificar se o genoma pertence ao género *Proteus* e determinar a espécie correspondente, constituindo uma validação inicial antes da análise do locus O.

A informação obtida é posteriormente utilizada para orientar as comparações com a base de referência.

3.10 Extração automática do locus O

Após a identificação da espécie, o sistema procede à localização dos genes fronteira *secB* e *cpxA*.

A região compreendida entre estes genes é extraída automaticamente, correspondendo ao locus O.

Esta abordagem permite reduzir significativamente a intervenção manual necessária para a obtenção da região de interesse.

3.11 Comparação com a base de referência

Os genes identificados no locus extraído são comparados com os perfis presentes na base de referência construída durante o projeto.

Esta comparação permite identificar semelhanças e diferenças relativamente aos loci previamente descritos para diferentes espécies e estirpes de *Proteus*.

3.12 Validação utilizando BLAST

Para complementar as comparações realizadas, foi utilizada a ferramenta BLAST.

O BLAST permite comparar sequências genéticas com bases de dados de referência, identificando sequências semelhantes e fornecendo uma medida adicional de validação dos resultados obtidos.

A utilização desta ferramenta permitiu confirmar a identidade de genes selecionados e apoiar a interpretação biológica dos resultados.

3.13 Estrutura geral da pipeline

A pipeline desenvolvida integra todas as etapas descritas anteriormente, desde a leitura do genoma até à geração dos resultados finais.

O fluxo geral de funcionamento encontra-se representado na Figura 4.




Figura 4: Fluxo geral de funcionamento do ProteusTyper.

4 Resultados

4.1 Base de referência

Foi construída uma base de referência contendo loci O previamente descritos para diferentes espécies do género *Proteus*.

Esta base reúne informação genética e metadados relevantes, permitindo a comparação sistemática de novos genomas com loci anteriormente caracterizados.

A Figura 3 apresenta um excerto da base de referência utilizada neste trabalho.

4.2 Análise de presença e ausência de genes

A partir das anotações produzidas pelo Prokka foi construída uma matriz binária de presença e ausência dos genes identificados nos loci O analisados.

Esta matriz permitiu visualizar a distribuição dos genes entre os diferentes genomas estudados.

O heatmap apresentado na Figura 5 evidencia a existência de genes conservados e genes variáveis entre os diferentes loci analisados.




Figura 5: Heatmap de presença e ausência dos genes identificados nos loci O analisados.

Os resultados evidenciaram a presença de genes associados à biossíntese e modificação do antígeno O, incluindo glicosiltransferases, polimerases e enzimas envolvidas no metabolismo de açúcares.

Observou-se que alguns genes estavam presentes em todos os genomas analisados, enquanto outros apenas surgiam em subconjuntos específicos. Esta variabilidade sugere a existência de diferentes organizações genéticas do locus O e potenciais diferenças estruturais entre os antígenos produzidos.

4.3 Clustering hierárquico

Com base na matriz de presença e ausência foi realizada uma análise de clustering hierárquico.

Esta abordagem permitiu agrupar genomas com perfis genéticos semelhantes e identificar relações entre os diferentes loci O.

O dendrograma apresentado na Figura 6 demonstra a existência de grupos de genomas que partilham características genéticas semelhantes.




Figura 6: Clustering hierárquico dos genomas analisados.

4.4 Genes core e accessory

A análise dos genes presentes nos loci permitiu distinguir genes core e genes accessory.

Os genes core correspondem aos genes observados em todos os genomas analisados, refletindo regiões mais conservadas do locus O.

Por outro lado, os genes accessory encontram-se presentes apenas num subconjunto dos genomas, contribuindo para a diversidade genética observada.

Esta análise permitiu identificar componentes conservados e variáveis dos loci estudados.

4.5 Aplicação da pipeline

A pipeline desenvolvida foi aplicada ao conjunto de vinte e seis genomas de *Proteus mirabilis*.

Os resultados obtidos demonstraram a capacidade do sistema para identificar automaticamente os loci O, extrair as regiões de interesse e realizar comparações com a base de referência.

Estes resultados evidenciam a viabilidade da metodologia desenvolvida e demonstram o potencial da ferramenta para apoiar futuras abordagens de tipagem molecular.

5 Discussão

Os resultados obtidos demonstram que o locus O apresenta uma variabilidade genética considerável entre diferentes genomas de *Proteus mirabilis*. Esta variabilidade era expectável, uma vez que esta região é responsável pela biossíntese do antígeno O, uma das estruturas mais variáveis do lipopolissacarídeo das bactérias Gram-negativas.

A análise de presença e ausência de genes permitiu identificar simultaneamente regiões conservadas e regiões variáveis. Os genes conservados encontram-se associados a funções essenciais para a manutenção da estrutura do locus, enquanto os genes variáveis contribuem para a diversidade observada entre diferentes antígenos O.

Os resultados obtidos através do heatmap e da análise de clustering demonstraram que diferentes genomas podem apresentar perfis genéticos distintos, evidenciando a utilidade destas abordagens para o estudo da diversidade genética dos loci O.

Um dos principais contributos deste trabalho foi o desenvolvimento do ProteusTyper, uma ferramenta capaz de integrar várias etapas da análise de loci O numa única pipeline automatizada. Em comparação com abordagens baseadas exclusivamente na utilização manual de ferramentas bioinformáticas, a metodologia desenvolvida permite reduzir o tempo de análise e melhorar a reprodutibilidade dos resultados.

A construção de uma base de referência específica para loci O de *Proteus spp.* constituiu igualmente um contributo relevante, uma vez que fornece uma estrutura organizada para futuras comparações e análises de novos genomas.

Apesar dos resultados obtidos, existem algumas limitações que devem ser consideradas. A validação foi realizada apenas utilizando genomas de *Proteus mirabilis*, não tendo sido avaliadas outras espécies do género *Proteus*. Adicionalmente, embora a infraestrutura necessária para a tipagem automática tenha sido desenvolvida, a validação completa da atribuição automática dos tipos O não foi concluída durante o período deste projeto.

Desta forma, os resultados apresentados devem ser interpretados como uma demonstração da viabilidade da metodologia proposta e da utilidade da pipeline desenvolvida, constituindo uma base para desenvolvimentos futuros.

6 Trabalho Futuro

O trabalho desenvolvido abre diversas possibilidades de evolução da ferramenta.

Uma das principais direções futuras consiste na implementação completa da atribuição automática de tipos O, permitindo que o sistema identifique automaticamente o perfil mais semelhante presente na base de referência.

Outra melhoria importante passa pela inclusão de genomas pertencentes a outras espécies do género *Proteus*, aumentando a abrangência da ferramenta e permitindo uma validação mais robusta.

A integração de metodologias de MLST (*Multi Locus Sequence Typing*) poderá complementar a análise dos loci O e fornecer informação adicional sobre a relação genética entre diferentes isolados [3].

Adicionalmente, poderão ser incorporadas análises de genes de resistência a antimicrobianos e fatores de virulência, permitindo uma caracterização genómica mais completa dos genomas analisados.

Finalmente, o desenvolvimento de uma interface gráfica poderá facilitar a utilização da ferramenta por utilizadores com menor experiência em bioinformática.

7 Conclusões

Neste trabalho foi desenvolvida uma metodologia para análise de loci O em genomas de *Proteus spp.*, culminando na implementação da ferramenta ProteusTyper.

Numa primeira fase foi realizada uma análise exploratória de seis genomas de *Proteus mirabilis*, permitindo estudar a variabilidade genética dos loci O através de anotações genéticas, matrizes de presença e ausência, heatmaps e análises de clustering.

Posteriormente foi construída uma base de referência contendo loci O previamente descritos para diferentes espécies de *Proteus*, constituindo um recurso fundamental para as comparações realizadas pela ferramenta.

A integração das diferentes etapas numa pipeline automatizada permitiu demonstrar a viabilidade da extração automática dos loci O, da comparação genética entre genomas e da organização sistemática dos resultados obtidos.

Embora a atribuição automática dos tipos O ainda necessite de validação adicional, os resultados alcançados demonstram o potencial do ProteusTyper como ferramenta de apoio à análise genómica de *Proteus spp.*

O trabalho desenvolvido estabelece uma base sólida para futuras extensões da ferramenta e para o desenvolvimento de abordagens mais avançadas de tipagem molecular baseadas em dados genômicos.

Referências

- [1] CE Armbruster and HLT Mobley. Merging mythology and morphology: the multifaceted lifestyle of proteus mirabilis. *Nature Reviews Microbiology*, 10(11):743–754, 2012.
- [2] MMC et al. Lam. Kaptive 2.0: updated capsule and lipopolysaccharide locus typing. *Microbial Genomics*, 8, 2022.
- [3] MCJ et al. Maiden. Multilocus sequence typing. *PNAS*, 95(6):3140–3145, 1998.
- [4] CRH Raetz and C Whitfield. Lipopolysaccharide endotoxins. *Annual Review of Biochemistry*, 71:635–700, 2002.
- [5] X. et al. Yu. Genetic diversity of the o antigens of proteus species. *PLOS ONE*, 12(4), 2017.